




HIPERTIREOIDISMO

Análise Preditiva com Machine Learning



Dados
de Pacientes



Análise
Exploratória



Modelos
Preditivos



Diagnóstico
Mais Preciso

Objetivo do projeto

- Elaboração de um mecanismo de auxílio a triagem clínica
- Identificar pacientes de forma precoce com hipertireoidismo a partir de:
 - Exames laboratoriais de rotina como: TSH, T3, TT4, T4U e FTI.
 - Dados cadastrais
 - Histórico de saúde





Modelo Preditivo de Hipertireoidismo

O modelo de Machine Learning foi desenvolvido com o intuito de prever de forma rápida e precisa casos de hipertireoidismo.



O principal objetivo do modelo é minimizar os casos de Falsos Negativos. Isso evita que pacientes com a doença fiquem sem tratamento.

INSIGHTS DOS PACIENTES


- 👥 70% mulheres | 30% homens
- 📊 Distribuição etária bimodal: picos aos 35 e 70 anos
- 🤰 53 mulheres grávidas
- 🏥 53 pacientes com histórico de cirurgia de tireoide



- **A distribuição de pacientes com outras doenças é bastante desbalanceada, com apenas aproximadamente 4% dos pacientes apresentando alguma doença além do hipertireoidismo.**
- **A distribuição de tumores por faixa etária acompanha o padrão bimodal da distribuição etária geral.** Isso sugere que não há uma faixa etária com predominância significativa de tumores, mas sim uma distribuição que acompanha, de maneira geral, a quantidade de indivíduos em cada faixa etária.



Ao contrário do que pode parecer intuitivo, **o uso de medicação antitireoidiana não se mostrou um fator determinante para a identificação de pacientes com hipertireoidismo!**



Modelos de Machine Learning utilizados

SVM

Support Vector Machine

O SVM busca encontrar o melhor hiperplano que separa as classes maximizando a margem entre elas. Os pontos mais próximos do hiperplano são os vetores de suporte.

Como funciona:




Encontra o melhor hiperplano de separação



Maximiza a margem entre as classes



Utiliza apenas os vetores de suporte para definir a fronteira




● Classe 0

■ Classe 1

XGBoost

eXtreme Gradient Boosting

O XGBoost é um algoritmo de boosting de árvore de decisão que combina múltiplas árvores fracas de forma sequencial para construir um modelo forte e altamente preditivo.



Principais características:



Alta performance e precisão



Lida bem com dados estruturados



Robusto a overfitting com regularização



Treinamento eficiente e escalável

Como funciona:

- 1 Constrói uma árvore de decisão inicial
- 2 Calcula os erros das previsões
- 3 Constrói novas árvores focando nos erros anteriores
- 4 Combina todas as árvores para uma predição final otimizada

Melhor resultado

- O modelo que minimizou os falsos negativos foi o **XGBoost**.
- O modelo acertou **99%** das previsões!
- Dos casos positivos, o modelo acertou **99,85%** das previsões

Acurácia: 99%

Recall: 99,85%

Benefícios do modelo

- Capacidade excepcional de identificar pacientes com hipertireoidismo.
- Alta taxa de classificações corretas.
- Baixíssimo número de falsos negativos